



Instituto Tecnológico de Aeronáutica – ITA

**ANÁLISE DE ESCOAMENTO EM SUPERFÍCIES
AERODINÂMICAS UTILIZANDO VISÃO COMPUTACIONAL**

Flow Analysis on Aerodynamic Surfaces Using Computer Vision

Projeto de Pesquisa - Doutorado

Aluno:

Cláudio Alexandre da Costa
Dias

Orientador:

Prof. Dr. Luiz Alberto
Vieira Dias

22 de setembro de 2022

Conteúdo

1	Introdução	4
2	Trabalhos Relacionados	5
3	Objetivo	5
4	Escopo da Pesquisa	6
5	Plano de Trabalho e Cronograma	6
6	Materiais e Métodos	6
7	Forma de Análise dos Resultados	7

Resumo

Nos últimos anos, os métodos de aprendizado profundo demonstraram superar as técnicas anteriores de aprendizado de máquina de última geração em vários campos, sendo a visão computacional um dos casos mais proeminentes [1].

Neste trabalho, propõe-se a criação de um sensor inteligente que seja capaz de analisar imagens de uma superfície aerodinâmica e, em tempo real, identificar regiões desta superfície que apresentem determinadas características.

Para isto, será desenvolvido e treinado um modelo de redes neurais convolucionais (CNN) capaz de identificar padrões na visualização de escoamento em superfícies aerodinâmicas.

Palavras chave – aprendizado de máquina; redes neurais convolucionais; transferência de aprendizado; aerodinâmica; escoamento.

Abstract

Over the last years deep learning methods have been shown to outperform previous state-of-the-art machine learning techniques in several fields, with computer vision being one of the most prominent cases [1].

In this work, we propose the creation of an intelligent sensor that is able to analyze images of an aerodynamic surface and, in real time, identify regions of this surface that present certain characteristics.

For this, a model of convolutional neural networks (CNN) capable of identifying patterns in the visualization of flow on aerodynamic surfaces will be developed and trained.

Keywords – machine learning; convolutional neural networks; transfer learning; aerodynamics; flow

1 Introdução

Na indústria aeronáutica, a necessidade de otimização da aerodinâmica é obviamente premente. Uma das técnicas frequentemente empregadas para esta otimização é a técnica de visualização de escoamento.

Várias técnicas de visualização de escoamento [2] são atualmente empregadas como visualização por fumaça, emprego de materiais sensíveis à distribuição de pressão sobre superfícies aerodinâmicas, e utilização de *tuffets* (tufos).

Na visualização do escoamento de superfícies aerodinâmicas em aeronaves em escala real (1:1) - em oposição à visualização em veículos em escala (empregados em túnel de vento, por exemplo) – dada a necessidade de embarcar-se a visualização durante o voo, a técnica dos tufos é preponderante sobre as demais.

Os tufos consistem em pequenos pedaços de lã, dispostos em *grid*, colados sobre a superfície aerodinâmica de interesse. A orientação dos tufos em relação ao escoamento indica claramente as características deste escoamento.



Figura 1: Tufos sobre a asa

Fonte: Embraer - Diretoria de Ensaio em Voo

Na indústria aeronáutica, o emprego de câmeras (de diversas resoluções e velocidades) foi a evolução tecnológica mais recente e notável, uma vez que anteriormente havia necessidade de embarcar-se o aerodinamicista no veículo de testes para observação em “tempo

real” do comportamento dos tufos durante o ensaio.

Com a adoção ampla do emprego de captura de imagens para visualização de escoamento, a análise dos resultados é atualmente feita por um ser humano treinado, durante reprodução das imagens gravadas a bordo. Tal técnica é frequentemente cansativa, extensa e maçante, dado o enorme volume de imagens normalmente adquiridas, além de bastante suscetível a erros (processo repetitivo) e altamente demandante.

Desta forma, o emprego de visão computacional na identificação de padrões nos tufos tem o potencial de substituir a atual técnica utilizada na análise.

2 Trabalhos Relacionados

Wang [3] disse que representar as emoções e consciência humanas ainda estavam no reino da ficção científica. Mas, muito mais importante, nos lembrou que as redes neurais são aproximadores universais de funções e deu alguns exemplos de redes neurais para previsão de séries temporais.

Atualmente, as redes neurais convolucionais fornecem uma boa base para a construção de um bom modelo de reconhecimento de padrões. Neste contexto, [4] apresenta resultados que sugerem fortemente que as *features* obtidas a partir de aprendizado profundo com redes convolucionais devam ser o principal candidato na maioria das tarefas de reconhecimento visual.

Muitos modelos têm sido disponibilizados, e têm sido bastante utilizados em tarefas de reconhecimento diferentes daquelas para os quais eles foram treinados. Esta técnica de transferência de aprendizado vem sendo largamente usada para criar novos modelos que se utilizam do conhecimento obtido pelos modelos originais. [5] quantificam generalidade versus especificidade dos neurônios em cada nível da rede e apresentam resultados que indicam transferir o aprendizado de *features*, mesmo de tarefas bem diferentes, pode ser melhor do que usar *features* aleatórias.

3 Objetivo

Criar de um sensor inteligente que seja capaz de analisar imagens de uma superfície aerodinâmica e, em tempo real, identificar regiões desta superfície que apresentem determinadas características.

Para isto, será desenvolvido e treinado um modelo de redes neurais convolucionais (CNN) capaz de identificar padrões na visualização de escoamento em superfícies aerodinâmicas.

4 Escopo da Pesquisa

Este trabalho de pesquisa contém os seguintes tópicos:

- Estudar e definir as características do escoamento numa superfície aerodinâmica;
- Estudar os tópicos pertinentes a este trabalho: aprendizado de máquina, redes neurais convolucionais, e transferência de aprendizado;
- Definir e classificar imagens de voos anteriores que serão utilizadas como bases de treinamento e teste para o modelo;
- Criar e treinar um modelo que classifique as imagens dos tufo de acordo com características pré-definidas;
- Testar, e validar o modelo em laboratório utilizando vídeos de voos anteriores; e
- Testar, e validar o modelo durante um ensaio.

5 Plano de Trabalho e Cronograma

- A. cursar disciplinas e realizar treinamentos pertinentes;
- B. Revisão da literatura;
- C. Estudar escoamento em superfícies aerodinâmicas;
- D. Estudar aprendizado de máquina, redes neurais convolucionais, e transferência de aprendizado;
- E. Desenvolver modelo de redes neurais convolucionais;
- F. Testar, e validar o modelo em laboratório; e
- G. Testar, e validar o modelo durante um ensaio.

Onde: ■ a fazer; x concluída.

6 Materiais e Métodos

Que materiais (placas de hardware, kits de desenvolvimento, itens de medição) são necessários para desenvolver sua pesquisa? Quais os métodos que vc pretende utilizar para desenvolver sua pesquisa? Colocar este tipo de informação nesta seção.

Tabela 1: Cronograma trimestral de atividades

	2020				2021				2022				2023				2024			
Trimestre	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4
A	x	x	x	x	x	x	x													
B								x	x				■		■					
C											x	■								
D				x	x	x	x	x	x	x	x	■	■	■						
E									x	x	x	■	■	■	■	■				
F										x	x	■	■	■	■	■	■			
G																	■	■		

7 Forma de Análise dos Resultados

Como verificar/analisar se o que vc produziu está correto? *Benchmark* disponível na literatura, estudos comparativos, reprodução de pesquisas? Como garantir a corretude dos resultados. Como verificar quão bom está o seu trabalho em relação ao que já existe atualmente?

Referências

- [1] A. Voulodimos, N. Doulamis, A. Doulamis, and E. Protopapadakis, “Deep learning for computer vision: A brief review,” *Computational intelligence and neuroscience*, vol. 2018, p. 7068349, 2018.
- [2] D. F. Fisher and R. R. Meyer Jr, “Flow visualization techniques for flight research,” in *AGARD Symposium of the Flight Mechanics Panel on Flight Test Techniques*, no. NAS 1.15: 100455, 1988.
- [3] S.-C. Wang, *Artificial Neural Network*, pp. 81–100. Boston, MA: Springer US, 2003.
- [4] A. S. Razavian, H. Azizpour, J. Sullivan, and S. Carlsson, “Cnn features off-the-shelf: an astounding baseline for recognition,” 2014.
- [5] J. Yosinski, J. Clune, Y. Bengio, and H. Lipson, “How transferable are features in deep neural networks?,” 2014.